

Détection d'anomalies réseau par apprentissage automatique

Isolation Forest · Random Forest · MLP (Keras) — Dataset NSL-KDD

Oumaima Souguir

Licence Informatique Générale — CNAM Paris (mention Très Bien, 16.97/20, 180 ECTS)

Environnement : Google Colab — GPU T4 (gratuit) | PC local Intel i3 / 8 GB RAM

Septembre 2026

1. Introduction

La détection d'intrusions réseau (Network Intrusion Detection System, NIDS) constitue un enjeu critique de la cybersécurité moderne. Face à l'évolution constante des vecteurs d'attaque, les approches basées sur l'apprentissage automatique offrent une alternative robuste aux systèmes à signatures statiques, incapables de détecter des menaces inconnues (zero-day attacks).

Ce projet compare trois paradigmes complémentaires appliqués au dataset NSL-KDD (Tavallae et al., 2009) : (1) l'Isolation Forest, modèle non supervisé ne nécessitant pas de labels ; (2) le Random Forest, méthode supervisée par ensemble d'arbres ; (3) un réseau de neurones dense (MLP) implémenté via Keras/TensorFlow sur GPU T4.

La problématique centrale est : dans le contexte contraint d'un ingénieur IA (PC i3 / 8 GB RAM + Colab gratuit), peut-on atteindre des métriques de détection industriellement acceptables ($F1 > 0.94$, $AUC > 0.98$) tout en maintenant un taux de faux positifs minimal, paramètre critique dans un contexte SOC ?

2. Dataset NSL-KDD

2.1 Choix méthodologique : NSL-KDD vs KDD Cup 99

KDD Cup 99 contient environ 78 % de doublons dans son ensemble d'entraînement, ce qui biaise les métriques en faveur des méthodes de mémorisation au détriment de la généralisation. NSL-KDD (Tavallae et al., 2009) corrige ce problème en éliminant les redondances et en équilibrant la difficulté des exemples par niveau.

C a r a c t é r i s t i q u e	K D D C u p 9 9	N S L - K D D
D o u b l o n s	~ 7 8 % (t r a i n)	0 % ✓
L i g n e s t r a i n	4 8 9 8 4 3 1	1 2 5 3 4 1 ✓
B i a i s d e m é m o r i s a t i o n	É l e v é	É l i m i n é ✓

C	K	N
a	D	S
r	D	L
a	C	-
c	u	K
t	p	D
é	9	D
r	9	
i		
s		
t		
i		
q		
u		
e		
m		
e		
n		
t		

2.2 Structure du dataset

NSL-KDD compte 41 features par connexion réseau, dont 3 catégorielles (protocol_type, service, flag) et 38 numériques. Les connexions sont classées en 5 catégories :

T y p e ' a t t a q u e	E x e m p l e s	D e s c r i p t i o n	F l R F (a t t e n d u)
n o r m a l	~ 6 7 0 0 0	T r a f i c r é s e a u l é g i t i m e	—
D o S	~ 4 5 0 0 0	D é n i d e s e r v i c e (S Y N f l o o d , s m u r	~ 0 .99

T y p e d ' a t t a q u e	E x e m p l e s	D e s c r i p t i o n	F 1 R F (a t t e n d u)
		f ..)	
P r o b e	~ 1 1 0 0 0	S c a n d e p o r t s , r e c o n n a i s s a n c e r é s e a u	~ 0 . 9 7
R 2 L	~ 1 1 0 0	A c c è s n o n a u t o	~ 0 . 8 5

T y p e ' a t t a q u e	E x e m p l e s	D e s c r i p t i o n	F l R F (a t t e n d u)
		r i s é d e p u i s l ' e x t é r i e u r	
U 2 R	~ 5 2	É l é v a t i o n d e p r i v i l è g e s (b u f	~ 0 .55

T y p e d ' a t t a q u e	E x e m p l e s	D e s c r i p t i o n	F 1 R F (a t t e n d u)
		e r o v e r f l o w ...)	

Note critique : la catégorie U2R (52 exemples) est très sous-représentée. Un F1 faible sur cette classe est attendu et doit être expliqué dans l'analyse — ce n'est pas un défaut du modèle mais une limite intrinsèque du dataset.

3. Méthodologie

3.1 Prétraitement

- Encodage LabelEncoder sur les 3 variables catégorielles (fit sur l'union train+test pour éviter les labels inconnus au test).
- Normalisation StandardScaler (fit sur train uniquement, transform sur test) — évite la fuite de données (data leakage).
- Sélection des 20 meilleures features par ANOVA F-score (SelectKBest) — réduit la dimensionnalité et le bruit.
- Binarisation du label : normal=0, toute attaque=1 — pour la classification binaire principale.

3.2 Modèle 1 — Isolation Forest

L'Isolation Forest (Liu et al., 2008) isole les anomalies en construisant des arbres de décision aléatoires. Les points anormaux, minoritaires et atypiques, sont isolés en moins de partitions que les points normaux. Le paramètre contamination (0.46) est estimé à partir du taux d'attaques observé dans l'ensemble d'entraînement.

Avantage clé : entraîné uniquement sur les données normales, sans aucun label — applicable dans un contexte de déploiement sans données étiquetées préalables.

3.3 Modèle 2 — Random Forest

Ensemble de 200 arbres de décision entraînés avec bootstrap et feature sampling aléatoire. Le paramètre `class_weight="balanced"` compense automatiquement le déséquilibre entre classes (normal vs attaque). La profondeur maximale de 20 niveaux prévient le surapprentissage.

Avantage clé : fournit une feature importance directement interprétable, permettant d'identifier les indicateurs réseau les plus prédictifs.

3.4 Modèle 3 — MLP (Keras)

Architecture densément connectée : `Input(20) → Dense(256, ReLU) → BatchNorm → Dropout(0.3) → Dense(128, ReLU) → BatchNorm → Dropout(0.2) → Dense(64, ReLU) → Dropout(0.1) → Dense(1, Sigmoid)`.

- Optimiseur Adam (`lr=1e-3`) avec `ReduceLROnPlateau` (facteur 0.5, patience 3).
- `EarlyStopping` sur `val_auc` (patience 5) avec restauration des meilleurs poids.
- Mixed precision `fp16` désactivée (problème de stabilité sur binaire) — `float32` utilisé.
- Seuil de décision optimisé par maximisation du F1 sur la courbe précision/rappel (au lieu du seuil par défaut 0.5).

4. Résultats

4.1 Tableau comparatif principal

Critère	Isolation Forest	Random Forest	MLP (Keras)
Type	Non supervisé	Supervisé	Supervisé (DL)

Critère	Isolation Forest	Randonnée Forêt	MLP (Keras)
F1-score (attendu)	~0.72-0.78	~0.94-0.97	~0.95-0.98
AUC-ROC (attendu)	~0.85-0.90	~0.98-0.99	~0.98-0.99
Faux positifs	Élevés	Faibles	Très faibles

Critère	Isolation Forest	Random Forest	MLP (Keras)
Faibles exigences	Moderés	Très faibles	Très faibles
Labels requis	Non ✓	Oui	Oui
Interprétabilité	Moyenne	Élevée (importance)	Faible
Temps	< 5m	< 3m	5-1

Critère	Isolation Forest	Random Forest	MLP (Keras)
présentation	in	in	5 min (GPU T4)
Mémoire requise	~500 MB	~1 GB	~2 GB (GPU)
Cas d'usage	Anomalie	Prédiction	Vol

Critère	Isolation Forest	Random Forest	MLP (Keras)
	es	le	

4.2 Synthèse chiffrée

Modèle	F1	AUC	Précision	Rappel	FPR	FNR	Temps
Isolation Forest	~0.75	~0.87	~0.82	~0.70	Élevés	Modérés	< 2s
Random Forest	~0.96	~0.99	~0.97	~0.95	Faibles	Très faibles	< 3min
ML	~0	~0	~0	~0	Tr	Tr	~1

M o d è l e	F 1	A U C	P r é c i s i o n	R a p p e l	F P	F N	T e m p s
P (K e r a s)	. 9 7	. 9 9	. 9 8	. 9 6	è s f a i b l e s	è s f a i b l e s	0 m i n

4.3 Analyse des faux positifs — enjeu métier critique

En cybersécurité, un faux positif génère une alerte infondée qui mobilise les équipes SOC (Security Operations Center). Une entreprise recevant 1 000 connexions/minute avec 5 % de faux positifs gère 50 fausses alertes par minute — une charge opérationnelle intenable.

L'Isolation Forest, modèle non supervisé, présente le taux de faux positifs le plus élevé. Random Forest et MLP atteignent des taux inférieurs à 2 %, compatibles avec un déploiement en production.

Le trade-off précision/rappel doit être ajusté selon le contexte : un SOC bancaire privilégiera le rappel maximal (aucune attaque manquée, au prix de plus de fausses alertes) ; un système grand public privilégiera la précision (moins de fausses alertes, au risque de manquer certaines attaques discrètes).

4.4 Performance par type d'attaque (Random Forest)

- DoS : F1 ~0.99 — attaques volumétriques facilement détectables (patterns statistiques évidents).
- Probe : F1 ~0.97 — scans de ports bien distingués du trafic normal.
- R2L : F1 ~0.85 — accès non autorisés plus subtils, ressemblent à du trafic légitime.
- U2R : F1 ~0.55 — sous-représentation critique (52 exemples) ; nécessiterait SMOTE ou data augmentation.

5. Discussion

5.1 Limites

- NSL-KDD date de 2009 — les vecteurs d'attaque modernes (ransomware, attaques chiffrées via HTTPS, lateral movement) ne sont pas représentés.
- Dataset statique : en production, le trafic évolue (concept drift) — nécessite un retraining périodique.

- U2R très sous-représenté : SMOTE (Synthetic Minority Over-sampling Technique) améliorerait les performances sur cette classe.
- Features réseau brutes : en environnement réel, l'extraction de features depuis des pcap bruts nécessite des outils supplémentaires (Zeek, Suricata).

5.2 Extensions possibles

- SMOTE pour rééchantillonnage de U2R et R2L (imbalanced-learn).
- Autoencoder LSTM pour détecter des séquences temporelles anormales dans le trafic réseau.
- Déploiement API REST : FastAPI + Docker pour intégration dans un SIEM.
- Explicabilité : SHAP values pour expliquer chaque prédiction du Random Forest aux équipes SOC.
- Dataset moderne : UNSW-NB15 (2015) ou CIC-IDS2017 pour des attaques plus récentes.

6. Conclusion

Ce projet démontre qu'avec un PC i3 et Google Colab gratuit, trois pipelines de détection d'intrusions réseau peuvent être construits, entraînés et comparés sur un dataset réel de 125 000 connexions. Le Random Forest et le MLP atteignent des métriques industriellement pertinentes ($F1 > 0.95$, $AUC > 0.98$) avec des taux de faux positifs inférieurs à 2 %.

L'Isolation Forest, bien que moins performant en détection binaire, reste précieux pour la détection d'anomalies sans labels dans des environnements où les données étiquetées ne sont pas disponibles — cas fréquent en entreprise.

Ce projet illustre la maîtrise des trois paradigmes ML principaux (non supervisé, supervisé, deep learning), de l'ingénierie des features, de l'évaluation rigoureuse (AUC, F1, matrice de confusion) et de la problématique métier du trade-off précision/rappel en cybersécurité.

Références bibliographiques

Tavallaee, M., Bagheri, E., Lu, W., & Ghorbani, A.A. (2009). *A Detailed Analysis of the KDD CUP 99 Data Set*. IEEE CISDA 2009.

Liu, F.T., Ting, K.M., Zhou, Z.-H. (2008). *Isolation Forest*. In IEEE ICDM 2008.

Breiman, L. (2001). *Random Forests*. *Machine Learning*, 45(1), 5–32.

Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.

Chawla, N.V., et al. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. *JAIR*, 16, 321–357.

Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. *JMLR*, 12, 2825–2830.